Eigenvector Centrality

I. Definiție

Eigenvector centrality este o măsură utilizată în teoria grafurilor și analiza rețelelor pentru a determina influența unui nod în funcție de calitatea conexiunilor sale, nu doar de cantitatea acestora. Conceptul a fost introdus pentru prima dată de Landau în 1895 în contextul turneelor de șah, redescoperit de Wei și popularizat de Kendall în clasamentele sportive, apoi formalizat de Phillip Bonacich în 1972 în contextul analizei sociale.

Ideea principală este că un nod este important dacă este conectat la alte noduri importante. Spre deosebire de măsurile simple precum degree centrality, eigenvector centrality captează conceptul recursiv de "prestigiu" sau "influență": conexiunile cu noduri influente contribuie mai mult la scorul propriu decât conexiunile cu noduri periferice.

Eigenvector centrality poate fi interpretată ca o măsură a "prestigiului" sau "autorității" recursive a unui nod într-o rețea. Este fundamentală în înțelegerea structurilor sociale, biologice și informaționale unde influența se transmite prin rețea.

II. Formula matematică

Eigenvector centrality pentru un nod este definită ca soluție a ecuației vectoriale:

$$\mathbf{c} = \frac{1}{\lambda} A\mathbf{c}$$

sau echivalent:

$$\lambda c_i = \sum_j A_{ij} c_j$$

unde:

- **C** – vectorul de centralitate (eigenvectorul)
- A – matricea de adiacență a grafului (dacă există muchie între și , 0 altfel)
- λ – cea mai mare valoare proprie (eigenvalue) a matricei (raza spectrală)
- c_i – centralitatea nodului (componenta a eigenvectorului)

În forma extinsă, pentru fiecare nod i :

$$c_i = \frac{1}{\lambda} \sum_{j \in N(i)} c_j$$

unde reprezintă vecinii nodului i.

Teorema Perron-Frobenius garantează că pentru grafuri conexe nedirecționate există un unic eigenvector dominant cu toate componentele pozitive corespunzător celei mai mari valori proprii.

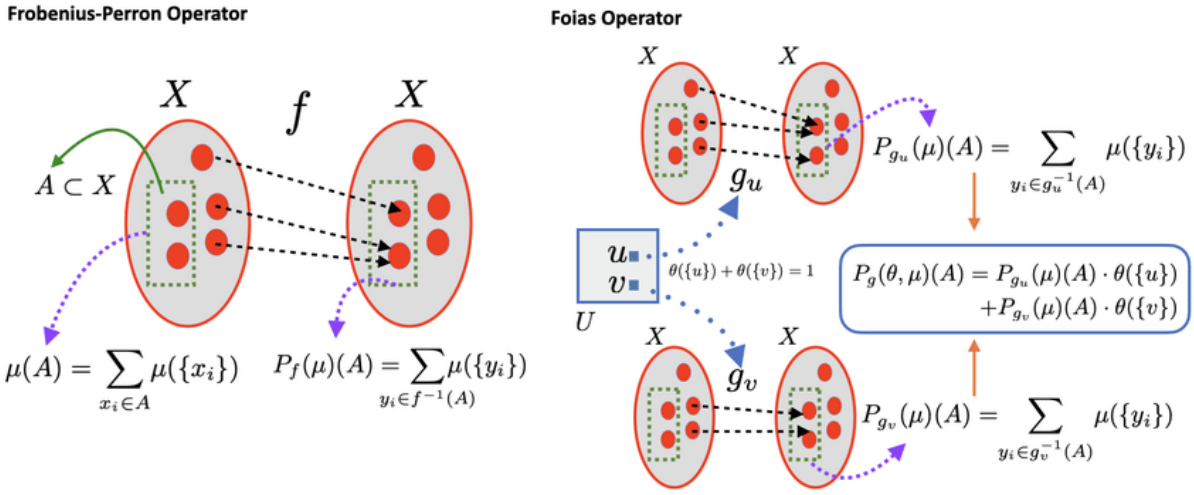

III. Interpretare

Valoarea eigenvector centrality indică influența relativă a unui nod în rețea:

- **Valoare mare** → nodul este conectat la alte noduri importante; are influență amplificată prin rețea; este considerat "prestigios" sau "autoritar"
- **Valoare mică** → nodul este conectat la noduri periferice sau are puține conexiuni; influența sa este limitată

Eigenvector centrality poate fi interpretată ca probabilitatea ca un nod să fie vizitat într-un proces de "random walk" infinit pe rețea, sau ca măsură a expunerii la fluxul de influență din rețea

.

Diferența crucială față de alte măsuri: Un nod cu degree mare (multe conexiuni) poate avea eigenvector centrality scăzut dacă vecinii săi sunt neimportanți. Invers, un nod cu puține conexiuni la noduri centrale poate avea eigenvector centrality ridicat

.

IV. Cum se calculează

Calcularea eigenvector centrality implică următorii pași:

1. **Se construiește matricea de adiacență A** a grafului, unde $A_{ij} = 1$ dacă există muchie între nodurile i și j (pentru grafuri ponderate, Aijreprezintă ponderea muchiei).
2. **Se calculează valorile și vectorii proprii** ai matricei A. Se selectează eigenvectorul c corespunzător celei mai mari valori proprii λmax.
3. **Se normalizează** vectorul astfel încât $\|\mathbf{c}\| = 1$ (normă euclidiană unitară) sau $\sum ici=1$

Metoda puterii (Power Iteration) - algoritm practic pentru grafuri mari:

$$\mathbf{c}^{(t+1)} = \frac{A\mathbf{c}^{(t)}}{\|A\mathbf{c}^{(t)}\|}$$

Se pornește cu un vector inițial $\mathbf{c}^{(0)}$ (de obicei vectorul cu toate componentele egale cu 1) și se iterează până la convergență (când $\|\mathbf{c}^{(t+1)} - \mathbf{c}^{(t)}\| < \epsilon$).

Observație importantă: Implementările moderne (NetworkX, rustworkx) folosesc (A + I) în loc de A pentru a deplasa spectrul și a asigura convergența chiar și pentru rețele cu valori proprii multiple.

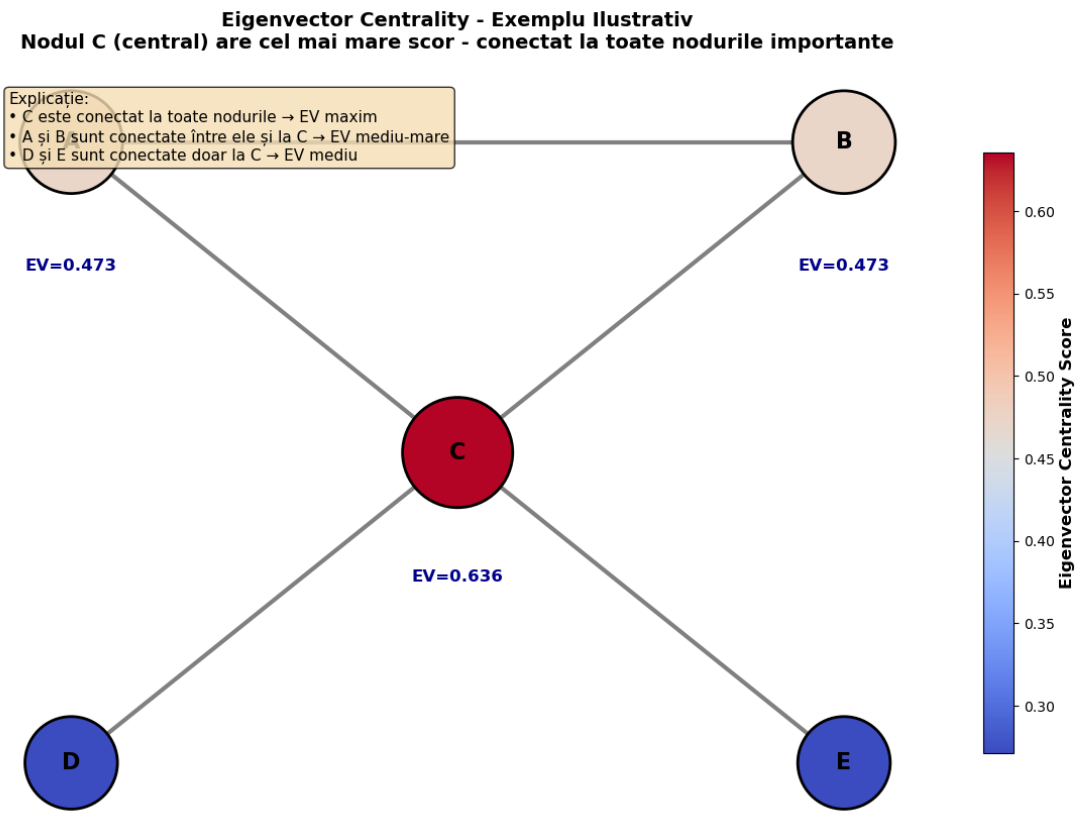

C: 0.6359

A: 0.4735

B: 0.4735

D: 0.2714

Explicație detaliată:

De ce C are cel mai mare Eigenvector Centrality?

- Este conectat la toate celelalte 4 noduri
- Toate "centrality"-urile celorlalte noduri "curg" către C prin conexiuni

- Este singurul nod care poate "ajunge" la toți ceilalți în 1 pas

De ce A și B au scoruri mai mari decât D și E?

- Pe lângă conexiunea la C, A și B mai au și conexiunea A-B între ele
- Aceasta creează o mică "rețea de suport" care crește reciproc scorurile

Formula aplicată:

$$\lambda c_C = c_A + c_B + c_D + c_E$$

$$\lambda c_A = c_C + c_B$$

$$\lambda c_B = c_C + c_A$$

Interpretare:

- C este "prestigios" pentru că este prieten cu toată lumea "prestigioasă"
- A și B formează o sub-comunitate care se susține reciproc
- D și E sunt "periferici" - au acces la centrul rețelei (C) dar nu au conexiuni între ei

V. Avantaje și Dezavantaje

Avantaje:

1. **Capturarea influenței recursive**: Măsoară nu doar numărul conexiunilor, ci calitatea acestora, identificând noduri conectate la "centre de putere" în rețea.
2. **Fundament matematic solid**: Bazat pe algebră liniară și teoria spectrală a grafurilor, cu garanții teoretice puternice (Perron-Frobenius).
3. **Eficiență computațională**: Metoda puterii converge rapid pentru grafuri mari sparse, cu complexitate pe iterație, unde este numărul de muchii.
4. **Aplicabilitate largă**: Funcționează excelent pentru grafuri nedirecționate și poate fi adaptat pentru grafuri ponderate.
5. **Identificare autorităților**: Detectează noduri care ar putea avea degree moderat dar poziție strategică în rețea (conectate la hub-uri)
6. **Consistență spectrală**: Eigenvectorul dominant captează structura globală a rețelei, fiind robust la perturbări locale.

Dezavantaje:

1. **Probleme cu grafuri direcționate**: În grafuri direcționate, eigenvector centrality poate conduce la scoruri nule pentru majoritatea nodurilor dacă există

noduri fără muchii de ieșire (dangling nodes), deoarece "centrality" nu se propagă înapoi.

2. **Sensibilitate la componente conexe**: Dacă graful are multiple componente conectate, doar componenta cea mai mare va avea valori nenule de eigenvector centrality (celelalte componente vor avea scoruri zero).

3. **Lipsa teleportării**: Spre deosebire de PageRank, nu are mecanism de "teleportare" pentru a trata nodurile fără ieșire sau pentru a asigura explorarea întregii rețele.

4. **Convergență neasigurată**: Metoda puterii poate eșua să convergă dacă matricea are valori proprii multiple de magnitudine maximă.

5. **Cost computațional pentru grafuri dense**: Deși eficient pentru grafuri sparse, calculul exact poate fi costisitor pentru matrice dense foarte mari.

6. **Interpretare limitată în rețele bipartite**: Poate produce rezultate counter-intuitive în grafuri bipartite unde eigenvectorul dominant alternează între cele două partiții.

7. **Ignorarea direcționalității în forma standard**: Versiunea clasică este proiectată pentru grafuri nedirecționate; adaptările pentru grafuri direcționate (left/right eigenvector) pot fi confuze.

VI. Aplicații Practice Detaliate

Eigenvector centrality este utilizat în numeroase domenii, fiind adaptat pentru a rezolva probleme specifice fiecărui context:

1. Analiza rețelelor sociale și identificarea influencerilor

Contextul problemei: În rețele sociale (Facebook, LinkedIn, Twitter), identificarea persoanelor influente nu se reduce la numărul de prieteni/urmăritori. O persoană cu puțini conexiuni la oameni importanți poate avea mai multă influență decât cineva cu multe conexiuni la persoane oarecare.

Cum funcționează implementarea:

- Nodurile reprezintă indivizi, muchiile reprezintă relații de prietenie sau profesionale
- Eigenvector centrality calculează recursiv: scorul unei persoane depinde de scorurile prietenilor săi
- În rețele direcționate (ex. Twitter), se folosește "left eigenvector centrality" care consideră muchiile intrante (cine te urmărește pe tine)

De ce Eigenvector Centrality este superior:

- **Detectarea "conectorilor"**: Identifică persoane care fac legătura între grupuri influente, chiar dacă nu au cel mai mare număr de conexiuni
- **Prestigiu vs. popularitate**: Distinge între popularitate (degree) și prestigiu real (conexiuni de calitate)
- **Stabilitate socială**: Persoanele cu eigenvector centrality mare tind să fie mai stabile în rețea și mai puțin susceptibile de a părăsi platforma

Beneficii concrete:

- Identificarea liderilor de opinie pentru campanii de marketing targetate
- Detectarea "brokers" - persoane care facilitează fluxul de informații între comunități
- Analiza coeziunii grupurilor și identificarea vulnerabilităților în structura socială

2. Neuroștiințe și analiza conectomului cerebral

Contextul problemei: În neuroștiințe, înțelegerea organizării rețelelor neuronale și a materiei albe este crucială pentru diagnosticarea bolilor neurologice. Identificarea regiunilor cerebrale "hub" care coordonează activitatea întregului creier ajută la înțelegerea cogniției și a tulburărilor

.

Cum funcționează implementarea:

- Nodurile reprezintă regiuni cerebrale sau neuroni, muchiile reprezintă conexiuni axonale sau corelații funcționale
- Eigenvector centrality identifică regiunile care sunt conectate la alte regiuni importante în rețeaua de materie albă
- Se aplică pe rețele construite din date DTI (diffusion tensor imaging) sau fMRI

De ce Eigenvector Centrality este superior:

- **Identificarea hub-urilor de integrare**: Regiunile cu eigenvector centrality mare servesc ca centre de integrare a informației din întregul creier
- **Corelație cu funcția**: Studiile arată că eigenvector centrality în rețelele de materie albă corelează cu măsurători de comportament social și cogniție
- **Biomarker pentru boli**: Modificări în eigenvector centrality pot indica debutul bolii Alzheimer, schizofreniei sau tulburărilor de spectru autist

Beneficii concrete:

- Identificarea țintelor pentru stimulare cerebrală profundă în boala Parkinson
- Predicția recuperării după accident vascular cerebral bazată pe integritatea hub-urilor de rețea
- Înțelegerea dezvoltării creierului și a plasticității neuronale