PageRank Centrality

I. Definiție

PageRank centrality este o măsură utilizată în teoria grafurilor și analiza rețelelor pentru a determina importanța unui nod într-un graf orientat, bazându-se pe calitatea și cantitatea legăturilor care indică spre acel nod. Conceptul a fost introdus de Larry Page și Sergey Brin în 1996 la Universitatea Stanford și a devenit fundația algoritmului de căutare Google .

Ideea principală este că un nod cu PageRank mare este considerat mai important nu doar pentru că are multe legături intrante, ci pentru că acele legături provin de la alte noduri importante. Astfel, un vot de la o pagină "importantă" valorează mai mult decât unul de la o pagină oarecare. PageRank poate fi interpretat ca probabilitatea ca un "surfist aleator" să ajungă la un anumit nod după ce navighează aleator prin graf pentru un timp infinit .

PageRank este frecvent utilizat pentru a analiza structura rețelelor web, influența nodurilor, și pentru a identifica entități cheie în diverse tipuri de rețele.

II. Formula matematică

PageRank pentru un nod este definit prin următoarea formulă recursivă:

$$PR(i) = (1-\alpha) \cdot \frac{1}{N} + \alpha \cdot \sum_{j \in B(i)} \frac{PR(j)}{L(j)}$$

unde:

- $PR(i)$ – PageRank-ul nodului
- N - numărul total de noduri din graf
- $B(i)$ - mulțimea nodurilor care au legături către nodul (backlinks)
- $L(j)$ - numărul de legături de ieșire ale nodului (out-degree)
- α - factorul de amortizare (damping factor), de obicei 0.85

În forma matricială, PageRank poate fi exprimat ca:

$$\mathbf{r} = \alpha \cdot P \cdot \mathbf{r} + (1-\alpha) \cdot \mathbf{v}$$

unde P este matricea de tranziție stocastică, iar **v** este vectorul de teleportare (de obicei uniform: $vi=1/N$) .

Factorul de amortizare reprezintă probabilitatea ca surfistul aleator să continue navigarea prin link-uri, în timp ce $(1-\alpha)$ reprezintă probabilitatea de "teleportare" către un nod aleatoriu oarecare din rețea .

III. Interpretare

Valoarea PageRank indică importanța relativă a unui nod în rețea:

- **Valoare mare** → nodul este considerat important, având multe legături intrante de la alte noduri importante; informația tinde să se concentreze aici
- **Valoare mică** → nodul este periferic, cu puține legături intrante sau cu legături doar de la noduri neimportante

PageRank poate fi interpretat ca o măsură a "popularității" sau "autorității" unui nod într-o rețea. Cu cât un nod este mai frecvent vizitat de surfistul aleator în stare staționară, cu atât este considerat mai central și mai influent în rețea .

IV. Cum se calculează

Calcularea PageRank implică următorii pași:

1. **Se construiește matricea de adiacență** A a grafului orientat, unde $Aji=1$ dacă există legătură de jla i la .
2. **Se normalizează** matricea pentru a obține matricea stocastică P, unde $P_{ji} = \frac{A_{ji}}{L(j)}$ (împărțirea la numărul de legături de ieșire ale nodului j).
3. **Se adaugă teleportarea** pentru a evita capcanele spider și nodurile fără ieșire (dangling nodes): $M=\alpha\cdot P+(1-\alpha)\cdot N1\cdot \mathbf{1}\mathbf{1}^T$
4. **Se aplică metoda puterii** (power iteration) pornind de la un vector inițial uniform

   $$\mathbf{r}^{(0)} = \frac{1}{N}\mathbf{1}: \quad \mathbf{r}^{(t+1)} = M \cdot \mathbf{r}^{(t)}$$

5. **Se iterează** până la convergență (când) .

Exemplu ilustrativ:

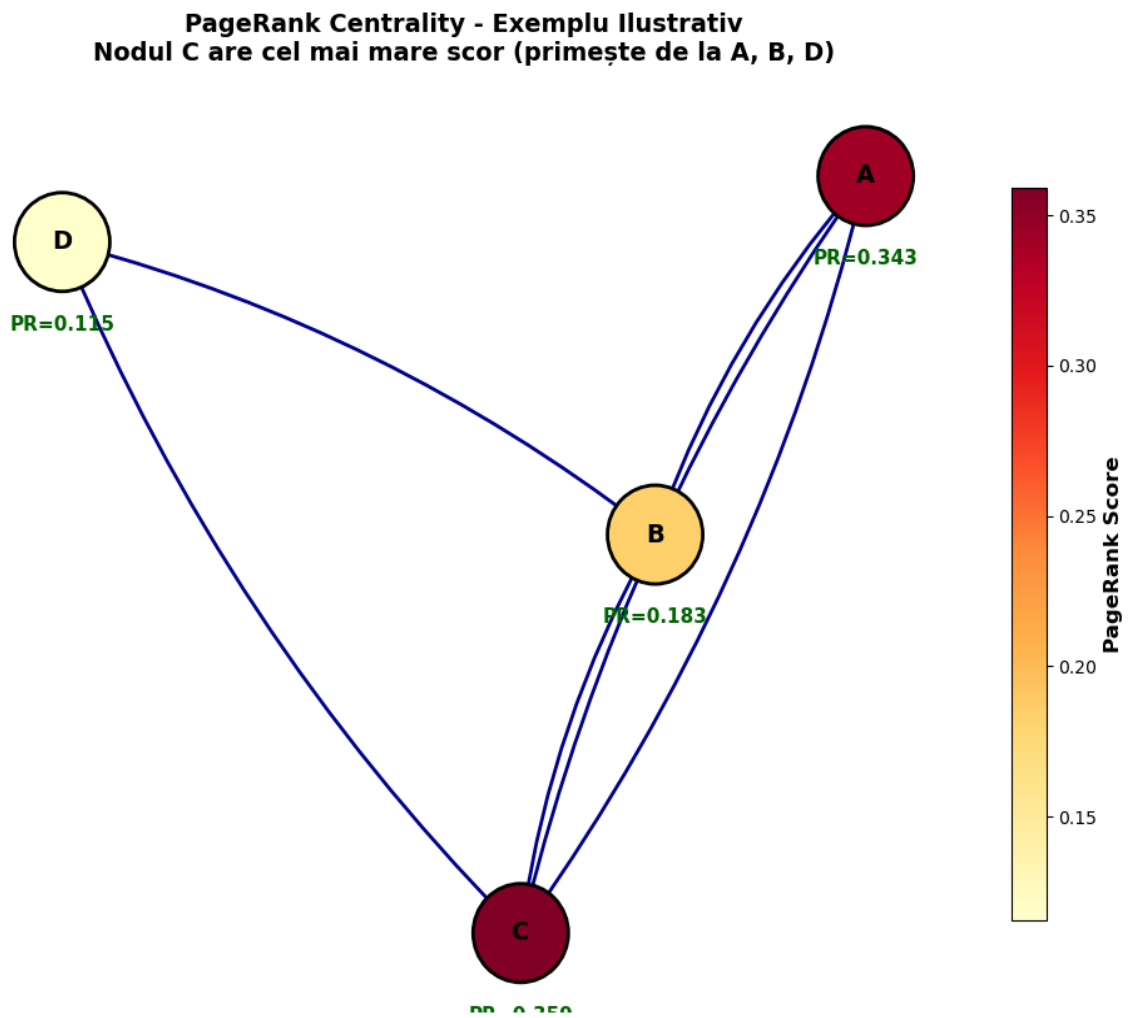

C: 0.3590

A: 0.3426

B: 0.1831

D: 0.1153

De ce C are cel mai mare PageRank?

- Primește 3 legături: de la A, B și D
- A are PageRank moderat (primește de la C)
- B are PageRank mic (doar primește de la A)
- D are PageRank minim (nu primește nicio legătură)

Formula aplicată:

$$PR(C) = \frac{1-0.85}{4} + 0.85 \cdot \left(\frac{PR(A)}{2} + \frac{PR(B)}{1} + \frac{PR(D)}{1} \right)$$

Interpretare:

- C este "autoritatea" în această rețea mică
- A este "hub-ul" care distribuie autoritatea către B și C
- D este periferic, oferă autoritate dar nu primește

Aplicând algoritmul cu :

- Inițial, toate nodurile au
- După iteratii, nodul C va avea cel mai mare PageRank (primește de la A, B, și D)
- Nodul D va avea PageRank mic (nu primește legături, doar oferă)

PageRank – Step 1

Page Rank (k = 1)					
	A	B	C	D	E
Old	1/5	1/5	1/5	1/5	1/5
New	4/15	2/5	1/6	1/10	

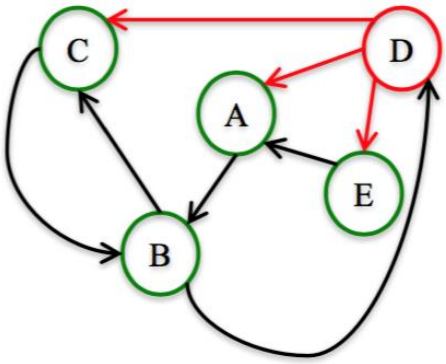

A: (1/3)*(1/5) + 1/5 = 4/15
B: 1/5 + 1/5 = 2/5
C: (1/3)*(1/5) + (1/2)*(1/5) = 5/30 = 1/6
D: (1/2)*(1/5) = 1/10
E: (1/3)*(1/5)

-

V. Avantaje și Dezavantaje

Avantaje:

1. **Robustete la spam**: Este dificil de manipulat deoarece adăugarea de link-uri artificiale de la pagini neimportante nu influențează semnificativ scorul; necesită link-uri de la pagini importante pentru a crește PageRank-ul .
2. **Măsură globală**: Consideră întreaga structură a rețelei, nu doar vecinătatea locală, oferind o perspectivă holistică asupra importanței nodurilor.
3. **Convergență garantată**: Datorită teleportării, matricea este pozitivă și stocastică, asigurând existența și unicitatea distribuției staționare conform teoremei Perron-Frobenius .
4. **Fundament teoretic solid**: Bazat pe teoria lanțurilor Markov și proceselor stocastice, oferind fundal matematic riguros .

5. **Scalabilitate**: Poate fi calculat eficient pentru grafuri mari folosind metoda puterii și implementări distribuite .
6. **Versatilitate**: Poate fi adaptat prin vectorul de teleportare pentru a crea PageRank personalizat (personalized PageRank) .

Dezavantaje:

1. **Vulnerabilitate la manipulare în practică**: Deși teoretic robust, în practică au apărut ferme de link-uri (link farms) și link-uri plătite care pot distorsiona rezultatele .
2. **Favorizează nodurile vechi**: Paginile noi au puține link-uri intrante, deci vor avea PageRank mic indiferent de calitatea conținutului .
3. **Ignoră conținutul**: Algoritmul consideră doar structura legăturilor, nu și calitatea sau relevanța conținutului nodurilor .
4. **Lipsă de transparență**: Google nu mai afișează scorurile PageRank publice din 2016, fiind necesare proxy-uri de la terți pentru estimare .
5. **Sensibilitate la parametri**: Valoarea factorului influențează rezultatele; valori mari ($\alpha \to 1$) pot duce la instabilități numerice .
6. **Cost computațional**: Pentru grafuri foarte mari (miliarde de noduri), calculul poate fi intensiv computațional, deși metoda puterii converge rapid .
7. **Relevanță redusă pentru interogări specifice**: PageRank este o măsură globală și nu ține cont de contextul specific al unei căutări (spre deosebire de HITS care este query-dependent) .

VI. Aplicații

PageRank centrality este utilizat în numeroase domenii, fiind adaptat pentru a rezolva probleme specifice fiecărui context:

1. Motoare de căutare (Web Search)

Contextul problemei: În anii 1990, motoarele de căutare existente (AltaVista, Yahoo) se bazau pe potrivirea cuvintelor cheie și frecvența acestora în pagini, rezultând în rezultate de căutare de slabă calitate și vulnerabile la manipulare prin keyword stuffing

.

Cum funcționează implementarea:

- Nodurile reprezintă paginile web, iar muchiile reprezintă hyperlink-uri între pagini
- PageRank calculează probabilitatea ca un utilizator care navighează aleator să ajungă la o anumită pagină
- Google combină PageRank cu alți factori (relevanța conținutului, autoritatea domeniului, viteza de încărcare) pentru ranking-ul final

De ce PageRank este superior:

- **Rezistență la spam**: Spre deosebire de metodele bazate pe frecvența cuvintelor cheie, PageRank este dificil de manipulat deoarece necesită link-uri de la site-uri importante
- **Calitatea rezultatelor**: Paginile cu PageRank mare tind să fie mai relevante și mai autoritare
- **Scalabilitate**: Algoritmul poate fi calculat pentru miliarde de pagini web

Beneficii concrete:

- Google a devenit cel mai popular motor de căutare datorită calității superioare a rezultatelor
- Reducerea manipulării prin tehnici SEO black-hat
- Oferă o măsură obiectivă a autorității unei pagini web

2. Rețele sociale și recomandări

Contextul problemei: Platformele sociale (Twitter, Facebook, LinkedIn) trebuie să identifice utilizatorii influenți pentru a recomanda conexiuni, conținut viral și conturi de urmărit. Identificarea simplă după numărul de urmăritori este insuficientă deoarece nu reflectă calitatea influenței

.

Cum funcționează implementarea:

- **Twitter**: Folosește Personalized PageRank pentru a calcula probabilitatea ca un utilizator să ajungă la profilul altcuiva prin navigarea prin rețeaua de follow-uri
- Nodurile sunt utilizatorii, muchiile sunt relațiile de follow/retweet/like
- Vectorul de teleportare personalizat este adaptat pentru fiecare utilizator în funcție de interesele sale

De ce PageRank este superior:

- **Influență reală vs. popularitate**: Un utilizator cu puțini urmăritori dar care sunt la rândul lor influenți poate avea PageRank mare
- **Personalizare**: PageRank personalizat permite recomandări adaptate fiecărui utilizator
- **Detectarea comunităților**: Nodurile cu PageRank similar tind să facă parte din aceleași comunități

Beneficii concrete:

- Recomandări mai relevante de conturi de urmărit, crescând engagement-ul platformei
- Identificarea influencerilor autentici pentru campanii de marketing

- Detectarea bot-ilor și conturilor false (au pattern-uri de link-uri anormale)