
Simulare SIR pe Rețele Complexe

Analiza Corelației dintre Centralități Clasice și Impactul Stochastic

Albul Valeria	Aldea Sebastian	Berindeiu Cosmin	Butyka Ana Maria
Carp Vasile	David Alexandru	David Tatiana	Hîrceagă Andreea
Iancu Gabriela	Lisnic Vlad	Lukacs Miruna	Manea Andrei
Matei Cătălin	Mircea Adrian	Muntean Maria Larisa	Mureșan Andreea
Nuțiu Iuliana	Oprean Dan	Ouș Andreea	Pascu Lorena
Plugar Mihai	Porcesco Daniel	Racz Christine	Robu Angel
Rojneai Mihai	Roman Nicolae	Sărăcsan Sorana	Seicean Daiana
Stefan Natalia	Tofan Mircea	Turcu Gabriela	Deva Dan
Zanfir Denis	Florea Patricia	Radu Ionut	

Coordonator: Bura Cotiso Andrei

Alba Iulia, 2026

Abstract

Lucrarea analizează capacitatea centralităților clasice — Degree, Closeness și Katz — de a prezice influența reală a nodurilor în propagarea epidemică simulată prin modelul SIR. Definim *centralități stohastice* ca media și respectiv maximul nodurilor infectate când fiecare nod acționează ca sursă, calculată empiric în urma la 300.000 de simulări.

Experimentul utilizează șase rețele cu 100 de noduri: trei reale și trei generate prin algoritmul GNM conex, cu densități de 2%, 5.6% și 20%. Pentru fiecare rețea s-au testat cinci probabilități de transmitere $p \in \{0.01, 0.04, 0.10, 0.30, 0.50\}$, cu 100 de repetări per combinație și limită de 200 de pași de transmisie. Centralitățile clasice au fost calculate cu NetworkX. Corelațiile Pearson, Spearman și Kendall între centralitățile clasice și cele stohastice au fost calculate cu SciPy.

Rezultatele arată că în regimul $p = 0.04 - 0.10$ centralitățile corelează puternic cu influența medie, *mean_inf*, confirmând ipoteza ca: există corelație pozitivă semnificativă între centralitățile clasice ale unui nod și impactul său epidemic mediu în modelul SIR, dar numai în regimuri de transmisibilitate intermediară. Pentru evaluarea riscului maxim, centralitățile clasice nu sunt predictorii fiabili. Pentru focarele maxime, *max_inf*, corelațiile sunt inconsistente, evenimentele extreme fiind dominate de varianță stohastică. La $p \geq 0.30$, saturația anulează contribuția structurală.

Concluzia este că măsurile clasice sunt eficiente doar pentru predicția comportamentului mediu în regimuri intermediare, fiind necesare simulări stochastice pentru evaluarea riscului extrem.

Cuprins

1	Introducere - Prezentarea problemei	5
2	Rețele - reale și sintetice	5
2.1	Rețele reale	5
2.2	Rețele sintetice	5
3	Centralități Clasice pentru Rețele	6
3.1	Degree Centrality	6
3.2	Closeness Centrality	6
3.3	Katz Centrality	7
4	Procesul SIR — Simulare Stocastică Discretă	7
4.1	Mecanismul de propagare	7
4.2	Parametrul p — Probabilitatea de infectare	8
4.3	Structura experimentului	8
4.4	Introducerea conceptului de centralitate stocastică	8
4.5	Limitări ale modelului	9
5	Centralitati stochastice	9
5.1	Definitia formală	9
5.2	Pipeline-ul de calcul: de la simulare bruta la centralitate	10
5.2.1	Etapa 1 — Extragerea stării finale per rulare	10
5.2.2	Etapa 2 — Agregarea statistică	11
5.3	Structura fisierului de ieșire	11
5.4	Configurația experimentului	12
5.5	Centralitățile clasice de referință	13
5.6	Vizualizare: distribuția centralității stochastice	13
5.7	Costul computațional	15
6	Corelații Statistice între Centralități	16
6.1	Tipuri de Coeficienți de Corelație	16
6.1.1	Coeficientul Pearson	16
6.1.2	Coeficientul Spearman	16
6.1.3	Coeficientul Kendall Tau	16
6.2	Degree Centrality — Analiza Corelației	17
6.2.1	Corelație cu mean_inf	17
6.2.2	Corelație cu max_inf	18
6.3	Closeness Centrality — Analiza Corelației	18
6.3.1	Corelație cu mean_inf	18
6.3.2	Corelație cu max_inf	19
6.4	Katz Centrality — Analiza Corelației	20
6.4.1	Corelație cu mean_inf	20
6.4.2	Corelație cu max_inf	20
6.5	Fenomenul de Corelație Negativă la $p = 0.10$	20
6.6	Implicații Practice	20
6.7	Concluzii Generale	21

7	Rezultate	21
7.1	Analiza Corelațiilor în Funcție de Parametrul p	21
7.2	Predictibilitatea Evenimentelor Extreme (max_inf)	23
8	Concluzii	23

1 Introducere - Prezentarea problemei

Identificarea nodurilor influente în rețele complexe este esențială pentru strategii de vaccinare, limitarea dezinformării și optimizarea rețelelor de transport. Centralitățile clasice precum Degree, Closeness și Katz oferă metrice rapide, calculate analitic din topologia grafului. Acestea presupun că poziția structurală aproximează impactul dinamic.

Totuși, procesele reale de difuzie sunt stohastice. Modelul SIR — Susceptibil, Infectat, Recuperat — modelează propagarea unui agent infecțios unde fiecare contact are probabilitatea p de transmitere. Un nod cu grad mare poate avea vecini deja imunizați, reducându-i influența efectivă.

Problema abordată: În ce măsură centralitățile clasice corelează cu impactul stohastic observat în SIR? Proiectul implementează un framework Python + NetworkX care rulează 300.000 de simulări pentru a măsura empiric influența fiecărui nod prin metricile *mean_total_infected* și *max_total_infected*.

Obiective:

1. Implementarea simulării SIR paralele în `runner.py` și `csv_generator.py`;
2. Calculul centralităților clasice în `C6_main_classical_centralities.py`;
3. Analiza corelației în `C8_classical_vs_stochastic_centralities.py`.

Ipoteza, este că centralitatea prezice bine doar influența medie în regimul $p \approx 0.04 - 0.10$, dar nu se cuplează evenimentele extreme.

2 Rețele - reale și sintetice

Experimentul utilizează trei rețele cu 100 de noduri, organizate în trei perechi real-generat pentru a izola efectul topologiei organice de cel al densității stohastice.

2.1 Rețele reale

Cele trei rețele reale sunt subgrafuri extrase din date empirice și preprocesate cu `programCuratare.py` pentru a păstra componenta maximă conexă. Fișierele sunt stocate în `grafuri_naturale_si_generate_curatate/`.

2.2 Rețele sintetice

Rețelele generate folosesc algoritmul GNM conex implementat în `main.py`. Algoritmul garantează că graful rezultat este conex, evitând componente izolate care ar distorsiona simularea SIR.

Raționament: Cele trei densități simulează contexte epidemiologice diferite: 1) **2%** — rețele rare, contacte sporadice; 2) **5.6%** — rețele sociale tipice; 3) **20%** — medii dense cu percolatie rapidă. Comparatia perechilor real-generat din `config.yaml` permite evaluarea impactului structurii naturale vs. aleatorii.

Toate rețelele sunt neorientate și neponderate. Simularea pornește cu un singur nod infectat și se oprește când nu mai există noduri Infectate sau după 200 de pași discreți.

Tabela 1: Configurațiile celor 6 rețele utilizate în experiment

Nume fișier	Tip	Noduri	Muchii	Densitate
99muchii_100noduri_natural	Reală	100	99	$\approx 2\%$
99muchii_100noduri_generat	Sintetică	100	99	$\approx 2\%$
275muchii_100noduri_natural	Reală	100	275	$\approx 5.6\%$
275muchii_100noduri_generat	Sintetică	100	275	$\approx 5.6\%$
1000muchii_100node_natural	Reală	100	1000	$\approx 20\%$
1000muchii_100noduri_generat	Sintetică	100	1000	$\approx 20\%$

3 Centralități Clasice pentru Rețele

Centralitatea unui nod este o măsură fundamentală în analiza rețelelor, indicând importanța sau influența relativă a acelui nod în cadrul grafului. Spre deosebire de centralitatea stocastică, care este estimată empiric prin simulări repetate, centralitățile clasice sunt derivate analitic din structura matematică a grafului. Aceste măsuri capturează proprietăți diferite ale poziției unui nod: conectivitate directă, accesibilitate globală, intermediaritate sau influență propagată [5].

În cadrul acestui proiect sunt analizate șase tipuri de centralitate clasică: **Degree Centrality**, **Closeness Centrality** și **Katz Centrality**.

3.1 Degree Centrality

Degree centrality este una dintre cele mai simple și intuitive măsuri de centralitate. Ea indică importanța unui nod în funcție de numărul de conexiuni directe (muchii) pe care le are cu alte noduri. Ideea de bază este că un nod cu mai multe conexiuni directe poate transmite sau recepționa mai rapid informații, resurse sau influență.

Formal, degree centrality pentru un nod v dintr-un graf $G = (V, E)$ este:

$$C_D(v) = \frac{\deg(v)}{n - 1} \quad (1)$$

unde $\deg(v)$ este gradul nodului (numărul de muchii incidente), iar $n = |V|$ este numărul total de noduri. Împărțirea la $n - 1$ normalizează valoarea în intervalul $[0, 1]$.

Complexitate computațională: $\Theta(V^2)$ pentru matrice de adiacență; $\Theta(E)$ pentru listă de adiacență.

Un grad mare semnifică multe conexiuni directe și capacitate ridicată de influențare imediată. Degree centrality este utilizată în epidemiologie pentru identificarea nodurilor cu risc mare de răspândire, în rețele sociale pentru detectarea persoanelor cu mulți prieteni, și în analiza internetului pentru identificarea hub-urilor.

3.2 Closeness Centrality

Closeness centrality măsoară cât de aproape este un nod față de toate celelalte noduri din rețea. Conceptul a fost introdus de Bavelas (1950) și reprezintă inversul sumei distanțelor minime de la nodul analizat la toți ceilalți.

Forma normalizată, care permite comparații între grafuri de dimensiuni diferite, este:

$$C_C(x) = \frac{n - 1}{\sum_{y \neq x} d(y, x)} \quad (2)$$

unde $d(y, x)$ este lungimea celui mai scurt drum dintre nodurile x și y , iar n este numărul total de noduri.

Calculul practic: Algoritmul implică: (1) selectarea unui nod x ; (2) calculul distanțelor minime către toate celelalte noduri folosind BFS (grafuri neponderate) sau Dijkstra (grafuri ponderate); (3) suma distanțelor; (4) aplicarea formulei.

Exemplu: Fie nodul B într-un graf cu 10 noduri, cu suma distanțelor egală cu 15. Atunci $C_C(B) = \frac{9}{15} = 0,6$.

Limitări: Closeness centrality funcționează bine doar în grafuri conexe (distanțele infinite în grafuri deconectate invalidează formula). Este utilizată pentru identificarea persoanelor care pot răspândi rapid informația în rețele sociale și pentru optimizarea fluxului de date în rețele de comunicații.

3.3 Katz Centrality

Katz centrality, introdusă de Leo Katz în 1953, extinde degree centrality luând în considerare *toți* vecinii unui nod, indiferent de distanță, dar ponderând contribuția exponențial cu distanța [4, 5]. Aceasta capturează influența globală a unui nod în rețea.

$$C_K(v) = \sum_{k=1}^{\infty} \alpha^k (A^k \mathbf{1})_v \quad (3)$$

unde α este factorul de atenuare ($\alpha < 1/\lambda_{\max}$, cu $\lambda_{\max}$ raza spectrală a matricei de adiacență A), iar A^k numără drumurile de lungime k între noduri.

Katz centrality măsoară influența globală ponderată: vecinii apropiați contribuie mai mult decât cei îndepărtați. Este deosebit de utilă în rețelele unde influența se propagă prin lanțuri lungi de conexiuni.

4 Procesul SIR — Simulare Stocastică Discretă

Modelul SIR (*Susceptibil–Infectat–Recuperat*) este un model epidemiologic clasic utilizat pentru a descrie propagarea unui agent infecțios într-o populație. Fiecare nod al rețelei poate fi într-una dintre cele trei stări:

- **S (Susceptibil)** — nodul poate fi infectat;
- **I (Infectat)** — nodul transmite infecția vecinilor;
- **R (Recuperat)** — nodul nu mai participă la propagare.

Modelul este discret în timp și evoluează în pași succesivi până la dispariția completă a infecției.

4.1 Mecanismul de propagare

La fiecare pas de timp, procesul evoluează după următoarele reguli:

1. Fiecare nod infectat încearcă să infecteze vecinii susceptibili;
2. Fiecare contact are probabilitatea p de transmitere;

3. Nodurile infectate trec ulterior în starea recuperată;
4. Simularea se oprește când nu mai există noduri infectate sau se atinge limita maximă de pași (200 de pași).

Tranzițiile pot fi descrise formal prin:

$$S + I \xrightarrow{p} I + I \quad (4)$$

$$I \xrightarrow{1} R \quad (5)$$

4.2 Parametrul p — Probabilitatea de infectare

Parametrul p reprezintă probabilitatea ca infecția să fie transmisă între două noduri conectate într-un pas de timp. Acesta controlează intensitatea procesului epidemic.

În cadrul experimentului sunt analizate următoarele valori:

$$p \in \{0.01, 0.04, 0.10, 0.30, 0.50\}$$

Aceste valori acoperă mai multe regimuri:

- p mic — propagare limitată, focare locale;
- p intermediar — propagare sensibilă la structura rețelei;
- p mare — propagare extinsă, tendință de saturație.

4.3 Structura experimentului

Simulările sunt realizate pe un set de rețele fixe, fiecare nod fiind considerat pe rând sursă a infecției. Pentru fiecare combinație de rețea și probabilitate p , procesul este repetat de mai multe ori pentru a captura variabilitatea stocastică.

Structura experimentului este următoarea:

- 6 rețele (3 reale și 3 generate);
- 100 noduri per rețea;
- 5 valori ale probabilității p ;
- 100 rulări pentru fiecare nod sursă.

În total, experimentul conține:

$$6 \times 5 \times 100 \times 100 = 300\,000 \text{ simulări}$$

4.4 Introducerea conceptului de centralitate stocastică

Pentru a evalua influența reală a fiecărui nod în procesul SIR, nu este suficientă analiza structurii statice a rețelei. Din acest motiv, se introduce conceptul de **centralitate stocastică**, care măsoară impactul empiric al unui nod ca sursă a epidemiei.

Această măsură se bazează pe rezultatele multiplelor simulări și reflectă numărul de noduri infectate generate de fiecare sursă. Detaliile formale, metodele de calcul și analiza statistică a centralității stocastice sunt prezentate în Capitolul 5.

4.5 Limitări ale modelului

Modelul utilizat prezintă câteva simplificări:

- recuperarea este permanentă (fără reinfecție);
- nu există perioadă de incubatie;
- rețeaua este statică;
- nu sunt considerați factori externi (vaccinare, intervenții).

Aceste simplificări permit însă o analiză clară a relației dintre structura rețelei și dinamica propagării.

5 Centralitati stochastice

Centralitatea stochastica a unui nod reprezintă măsura empirică a influenței sale reale în procesul de propagare SIR, calculată prin agregarea statistică a rezultatelor a sute de simulări independente. Spre deosebire de centralitățile clasice (Degree, Closeness, Katz), care sunt calculate analitic din structura grafului, centralitatea stochastica reflectă *comportamentul observat* al fiecărui nod ca sursă a unei epidemii [1, 2].

În cadrul proiectului **Simulare SIR**, centralitatea stochastica a fost obținută prin două etape succesive de procesare a rezultatelor brute ale simulării (din `raw_results.csv`): mai întâi s-a extras starea finală a fiecărei rulari individuale (`final_per_run.csv`), apoi s-au agregat statistic toate rularile cu același nod sursă pentru a obține `stochastic_centrality_summary.csv`.

5.1 Definiția formală

Fie $G = (V, E)$ un graf neorientat, p probabilitatea de infecție într-un pas, și R numărul de rulari independente ale modelului SIR pornite din nodul sursă $v \in V$. Notăm cu $I_r(v)$ numărul total de noduri infectate în rularea $r \in \{1, \dots, R\}$. Centralitatea stochastica a nodului v , la probabilitatea p , se definește prin **metrici agregate** extrase din distribuția $\{I_1(v), I_2(v), \dots, I_R(v)\}$:

$$\bar{I}(v, p) = \frac{1}{R} \sum_{r=1}^R I_r(v) \quad (\text{mean_total_infected}) \quad (6)$$

$$I_{\max}(v, p) = \max_{r=1, \dots, R} I_r(v) \quad (\text{max_total_infected}) \quad (7)$$

În folderul proiectului s-au calculat de asemenea și:

$$\tilde{I}(v, p) = \text{median}(I_1(v), \dots, I_R(v)) \quad (\text{median_total_infected}) \quad (8)$$

$$\sigma^2(v, p) = \frac{1}{R-1} \sum_{r=1}^R (I_r(v) - \bar{I}(v, p))^2 \quad (\text{variance_total_infected}) \quad (9)$$

La acestea se adaugă `std_total_infected` (deviația standard σ), `skewness_total_infected` (coeficientul de asimetrie), `min_total_infected` și `mean_final_tick` (numărul mediu de pași până la stingerea epidemiei).

De ce mai multe metrice si nu doar media?

Distributia $I_r(v)$ nu este simetrica (din cauza saturatiei la numarul total de noduri si a focarelor sporadice). Media ($\bar{I}$) descrie comportamentul *tipic*, maximul ($I_{\max}$) descrie *cel mai rau scenariu*, iar varianta si asimetria masoara *stabilitatea* si *forma* distributiei. Cele doua metrice folosite efectiv in analiza corelationala sunt `mean_inf` si `max_inf`.

5.2 Pipeline-ul de calcul: de la simulare bruta la centralitate

Calculul centralitatii stochastice se face in doua etape, fiecare implementata intr-un script Python distinct.

5.2.1 Etapa 1 — Extragerea starii finale per rulare

Fisierul brut `raw_results.csv` contine *toate snapshot-urile* fiecărei simulări (cate o linie pentru fiecare `tick`). Pentru analiza centralitatii este nevoie doar de *starea finala* a fiecărei rulari (numarul total de noduri infectate la sfarsit). Scriptul de preprocesare:

1. Verifica prezenta coloanelor obligatorii (`rete`, `sursa`, `p`, `run_id`, `ticks`, `nr_infectati`);
2. Detecteaza per `rete` daca exista nodul 0; daca nu, incrementeaza toate id-urile `sursa` cu +1 pentru a uniformiza indexarea cu fisierele de centralitati clasice;
3. Pentru fiecare combinatie (`rete`, `sursa`, `p`, `run_id`) retine *doar randul cu cel mai mare tick*, adica starea finala a rularii;
4. Redenumeste coloanele in nomenclatura standard (`network`, `source_vertex`, `infection_probability`, `run`, `tick`, `total_infected`);
5. Salveaza rezultatul in `final_per_run.csv`.

Listing 1: Extragerea starii finale per rulare (fragment)

```

1 # pastreaza doar ultimul rand al fiecarui run
2 idx = df.groupby(['rete', 'sursa', 'p', 'run_id'])['ticks'].
    idxmax()
3
4 final_per_run = (
5     df.loc[idx, ['rete', 'sursa', 'p', 'run_id', 'ticks', '
        nr_infectati']]
6     .sort_values(['rete', 'p', 'sursa', 'run_id'])
7     .rename(columns={
8         'rete': 'network',
9         'sursa': 'source_vertex',
10        'p': 'infection_probability',
11        'run_id': 'run',
12        'ticks': 'tick',
13        'nr_infectati': 'total_infected'
14    })
15     .reset_index(drop=True)
16 )

```

Ajustarea indexarii. Grafurile generate sintetic au nodurile numerotate de la 0, iar grafurile reale (extrase din liste de muchii) de la 1. Pentru a putea face merge corect cu fisierele de centralitati clasice, codul detecteaza automat fiecare retea si aplica incrementul doar acolo unde este necesar:

```
1 has_zero = df.groupby('retea')['sursa'].transform(lambda x: (x
    == 0).any())
2 df.loc[~has_zero, 'sursa'] = df.loc[~has_zero, 'sursa'] + 1
```

5.2.2 Etapa 2 — Agregarea statistica

Din `final_per_run.csv` se calculeaza centralitatea stochastica prin agregarea celor R rulari ale fiecarui nod sursa, la fiecare probabilitate p :

Listing 2: Agregarea metricilor stochastice

```
1 summary = (
2     final_per_run
3     .groupby(['network', 'infection_probability', '
4         source_vertex'],
5         as_index=False)
6     .agg(
7         mean_total_infected=('total_infected', 'mean'),
8         median_total_infected=('total_infected', 'median'),
9         variance_total_infected=('total_infected', 'var'),
10        std_total_infected=('total_infected', 'std'),
11        skewness_total_infected=('total_infected', 'skew'),
12        min_total_infected=('total_infected', 'min'),
13        max_total_infected=('total_infected', 'max'),
14        mean_final_tick=('tick', 'mean')
15    )
16    .sort_values(
17        ['network', 'infection_probability', '
18            mean_total_infected'],
19        ascending=[True, True, False]
20    )
21    .reset_index(drop=True)
22 )
23 summary.to_csv("stochastic_centrality_summary.csv", index=False)
```

Sortarea descrescatoare dupa `mean_total_infected` aseaza nodurile cu cea mai mare influenta medie in topul tabelului, ceea ce permite identificarea rapida a *spreader-ilor influenti* [2] pentru fiecare combinatie retea- p .

5.3 Structura fisierului de iesire

Rezultatul final, `stochastic_centrality_summary.csv`, este tabelul-cheie folosit in toate analizele ulterioare. Are urmatoarele coloane:

Tabela 2: Schema fisierului `stochastic centrality summary.csv`

Coloana	Tip	Semnificatie
<code>network</code>	string	Identificator retea (ex. 99muchii_100noduri_natural)
<code>infection_probability</code>	float	Valoarea p folosita la simulare
<code>source_vertex</code>	int	Id-ul nodului sursa al epidemiei
<code>mean_total_infected</code>	float	Media nodurilor infectate pe toate rularile
<code>median_total_infected</code>	float	Mediana, robusta la outliers
<code>variance_total_infected</code>	float	Varianta esantionala σ^2
<code>std_total_infected</code>	float	Deviatia standard σ
<code>skewness_total_infected</code>	float	Asimetria distributiei (semnal de focare extreme)
<code>min_total_infected</code>	int	Cel mai mic focar observat
<code>max_total_infected</code>	int	Cel mai mare focar observat (<code>max_inf</code>)
<code>mean_final_tick</code>	float	Numarul mediu de pasi pana la stingerea epidemiei

5.4 Configuratia experimentului

Centralitatea stochastica a fost calculata pentru toate combinatiile (retea, p , nod sursa, rulare) din urmatorul *design factorial complet*:

Tabela 3: Designul experimental al simularii SIR

Factor	Cardinalitate	Valori
Retele	6	3 generate sintetic + 3 reale
Densitati per tip	3	99, 275, 1000 muchii (la 100 noduri)
Probabilitati p	5	{0.01, 0.04, 0.10, 0.30, 0.50}
Noduri sursa per retea	100	toate nodurile, pe rand
Rulari per combinatie	100	pentru stabilitate statistica
Total simulari	$6 \times 5 \times 100 \times 100 = 300\,000$	

Maparea exacta intre numele scurte ale retelelor (folosite in cod) si denumirile lor canonice (folosite in fisierele CSV) este definita in dictionarul `NETWORK_MAP`:

Listing 3: `NETWORK_MAP` — maparea retelelor

```

1 NETWORK_MAP = {
2     "graf_generat_100_99":    "99muchii_100noduri_generat",
3     "graf_generat_275_100":  "275muchii_100noduri_generat",
4     "graf_generat_100_1000": "1000muchii_100noduri_generat",
5     "graf_real_100_99":      "99muchii_100noduri_natural",
6     "graf_real_100_275":     "275muchii_100noduri_natural",
7     "graf_real_100_1000":    "1000muchii_100noduri_natural",
8 }
```

5.5 Centralitatile clasice de referinta

Pentru a putea evalua *cat de bine prezic* centralitatile clasice influenta stochastica, fiecare retea are precalculate scorurile **Degree**, **Closeness** si **Katz** pentru toate nodurile. Acestea sunt stocate ca CSV-uri cu o singura coloana (scorul per nod, in ordinea index-ului), in folderul `scoruri_centralitati_clasice/`, dupa conventia de numire:

`{centralitate}_{retea_canonica}_output.csv`

(de exemplu `degree_99muchii_100noduri_natural_output.csv`).

Listing 4: Incarcarea centralitatilor clasice cu corectie de indexare

```

1 def load_centralities():
2     data = {}
3     for net_key, net_name in NETWORK_MAP.items():
4         data[net_key] = {}
5         for ctype in CENTRALITY_TYPES:
6             filename = f"{ctype}_{net_name}_output.csv"
7             path = os.path.join(CENTRALITY_FOLDER, filename)
8
9             df = pd.read_csv(path, header=None, names=["score"
10                ])
11
12             # grafurile generate sintetic incep de la 0,
13             # cele reale de la 1
14             if "generat" in net_name:
15                 df["node"] = df.index
16             else:
17                 df["node"] = df.index + 1
18
19             df = df.set_index("node")
20             data[net_key][ctype] = df["score"]
21
22     return data

```


Important pentru reproducibilitate: Asimetria de indexare *0-based vs. 1-based* este una dintre cele mai frecvente surse de eroare in pipeline-uri pe grafuri. Codul foloseste acelasi mecanism de detectie automata in *ambele* scripturi (extragerea starii finale si incarcarea centralitatilor), garantand ca in momentul calculului corelatiei nodul i din *classical* corespunde *exact* nodului i din *stochastic*.

5.6 Vizualizare: distributia centralitatii stochastice


Pentru fiecare combinatie retea- p , centralitatea stochastica produce un vector de 100 de valori (cate una pentru fiecare nod sursa). Vizualizarea acestor vectori sub forma de *histograme* sau *rank-plots* dezvaluie informatii esentiale despre dinamica epidemiei:

- La p mic ($p = 0.01$): distributia este *puternic asimetrica la dreapta* — majoritatea nodurilor produc focare mici (1–5 infectati), iar cateva noduri “noro-


coase” produc focare moderate. `skewness_total_infected` este mare pozitiv.



- La p intermediar ($p = 0.10$): distribuția se întinde și devine *bimodală* sau largă — structura rețelei contează cel mai mult, iar diferențele între noduri sunt maxime.



- La p mare ($p = 0.50$): distributia se *concentreaza* la valori apropiate de $|V|$ (saturatie completa); diferentele intre noduri devin nesemnificative ($\sigma \rightarrow 0$, `variance_total_infected` mic).



Aceste observatii motiveaza folosirea *mai multor probabilitati* p in design-ul experimental: comportamentul centralitatii stochastice este *regim-dependent*, iar concluziile valabile la o probabilitate nu se transfera automat la alta.

5.7 Costul computational

Pentru a obtine centralitatea stochastica exacta pe un graf cu $|V|$ noduri sunt necesare aproximativ:

$$T_{\text{total}} \approx |V| \cdot |P| \cdot R \cdot T_{\text{sim}}(|V|, p) \quad (10)$$

unde $|P|$ este numarul de probabilitati testate, R numarul de rulari per combinatie, iar T_{sim} timpul mediu al unei simulari SIR (depinde de densitatea rețelei si de p). Pentru designul nostru ($|V| = 100$, $|P| = 5$, $R = 100$, 6 rețele), costul total este de **300.000 de simulari**, executate in paralel pentru a face problema tractabila pe hardware obisnuit.

Avantajul fundamental al centralitatii stochastice: spre deosebire de centralitatile clasice, care reflecta doar structura *statica* a grafului, centralitatea stochastica integreaza *interactiunea* dintre topologie si dinamica de propagare. Costul este insa cu ordine de marime mai mare (300 000 simulari vs. un singur calcul $O(|V|^3)$). Aceasta motiveaza intrebarea-cheie a capitoului urmator: *cat de bine pot centralitatile clasice prezice centralitatea stochastica*, evitand astfel costul simulării?

6 Corelatii Statistice intre Centralitati

Aceasta sectiune analizeaza corelatia dintre centralitaile clasice (Degree, Closeness, Katz) si impactul nodurilor in simularea SIR, masurata prin doua metrici: **mean_inf** si **max_inf**. Analiza se realizeaza pentru 5 valori ale lui p , permitand observarea comportamentului corelatiei in diferite regimuri epidemice [1, 2].

6.1 Tipuri de Coeficienti de Corelatie

6.1.1 Coeficientul Pearson

Coeficientul Pearson masoara dependentia liniara dintre doua variabile continue. Valoarea variaza in $[-1, 1]$: 1 indica corelatie pozitiva perfecta, -1 corelatie negativa perfecta, 0 absenta relatiei liniare.

$$r_P = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot \sum_{i=1}^n (y_i - \bar{y})^2}} \quad (11)$$

unde x_i sunt scorurile de centralitate clasica si y_i sunt scorurile stochastice ale nodurilor. Presupune normalitate, liniaritate si homoscedasticitate.

6.1.2 Coeficientul Spearman

Coeficientul Spearman masoara dependentia monotona prin compararea rangurilor variabilelor, fara a presupune o relatie liniara. Este mai robust la outliersi si distributii asimetrice [3].

$$r_S = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)} \quad (12)$$

unde d_i este diferenta dintre rangurile celor doua variabile pentru observatia i . In contextul proiectului, evalueaza daca ordinea nodurilor dupa centralitate clasica se pastreaza si dupa impactul observat in simulare.

Interpretare Spearman in contextul proiectului:

$r_S \approx 1$ — nodurile cu centralitate mare tind sa aiba si impact mare in SIR (concordanta puternica a clasamentelor);

$r_S \approx 0$ — nu exista o relatie clara intre centralitate si impact;

$r_S \approx -1$ — nodurile cu centralitate mare tind sa aiba impact mic (ordinea inversata).

6.1.3 Coeficientul Kendall Tau

Kendall Tau masoara proportia de perechi concordante din totalul perechilor posibile:

$$\tau = \frac{n_{\text{concordante}} - n_{\text{discordante}}}{n(n-1)/2} \quad (13)$$

O pereche este **concordanta** daca ordinea este aceeaasi in ambele clasamente ($x_i < x_j$ si $y_i < y_j$), **discordanta** daca ordinea difera. Kendall este mai conservator decat Spearman, dar mai direct interpretabil ca probabilitate de concordanta.


6.2 Degree Centrality — Analiza Corelatiei

6.2.1 Corelatie cu mean_inf

Tabela 4: Corelatia Degree vs. mean_inf in functie de p

p	Pearson	Spearman	Kendall	Interpretare
0.01	≈ 0.51	≈ 0.53	≈ 0.39	Moderata — structura locala conteaza, relatia nu e determinista
0.04	≈ 0.70	≈ 0.68	≈ 0.52	Puternica — gradul devine predictor bun; epidemia percoleza
0.10	≈ 0.82	≈ 0.81	≈ 0.64	Foarte puternica — ranking dupa grad $\approx$ impact SIR
0.30	≈ 0.45	≈ 0.42	≈ 0.30	Scade — regim partial saturat
0.50	≈ 0.05	≈ 0.04	≈ 0.02	Aproape zero — saturatie; gradul nu mai conteaza


Degree centrality este un predictor foarte bun al influentei medii doar in regimul intermediar al lui p (≈ 0.04 – 0.10), unde procesul SIR este sensibil la structura rețelei. La probabilitati mici epidemia nu percoleza suficient; la probabilitati mari, saturatia elimina diferentele.



6.2.2 Corelatie cu $\max_inf$

Comportamentul corelatiei degree cu $\max_inf$ este fundamental diferit si mai instabil:

- $p = 0.01-0.04$: Corelatie mica pozitiva ($\approx 0.1-0.2$ pentru Pearson). Evenimentele extreme sunt dominate de variatii stochastice.
- $p = 0.10$: Corelatie **negativa** (≈ -0.15 pentru Pearson). Fenomen critic: nodurile foarte conectate nu maximizeaza neaparat focarul maxim.
- $p \geq 0.30$: Valori irelevante statistic; saturatia elimina diferentele.



Concluzie Degree: Degree nu este un predictor util pentru evenimentele extreme ($\max_inf$) ale SIR. Diferentele dintre Pearson, Spearman si Kendall indica ca relatia nu este nici liniara, nici monotona si stabila la valorile extreme ale lui p .

6.3 Closeness Centrality — Analiza Corelatiei

6.3.1 Corelatie cu mean_inf

Closeness centrality urmeaza un pattern similar cu degree, cu nuante importante:


- $p = 0.01$: Corelatie moderata (≈ 0.50 Pearson) — pozitia globala favorizeaza propagarea, dar nu decisiv.
- $p = 0.04$ si $p = 0.10$: Corelatie foarte mare ($\approx 0.70-0.82$ Pearson), comparabila sau usor superioara degree in unele cazuri. In regimul epidemic activ, pozitia globala in retea devine mai relevanta decat numarul de conexiuni directe.

- $p = 0.30\text{--}0.50$: Corelatie scade mult (spre ≈ 0) — saturatia elimina diferentele structurale.



6.3.2 Corelatie cu max_inf

Corelatie pozitiva mica la p mic ($\approx 0.1\text{--}0.2$), negativa la $p = 0.10$ (≈ -0.18 Pearson). Inconsistenta intre cei trei coeficienti indica lipsa unei relatii stabile. Closeness nu este predictor pentru extremele SIR.



Concluzie Closeness: Este cel mai bun predictor al influenței medii în regimul intermediar, reflectând că accesibilitatea globală contează mai mult decât conectivitatea locală în fazele active ale epidemiei.

6.4 Katz Centrality — Analiza Corelației

6.4.1 Corelație cu `mean_inf`

Katz centrality arată o corelație consistentă și similară cu celelalte:

- $p = 0.01$: ≈ 0.50 Pearson — moderat.
- $p = 0.04\text{--}0.10$: $\approx 0.68\text{--}0.80$ Pearson — confirmat și de Spearman și Kendall.
- $p = 0.30\text{--}0.50$: Scade de la ≈ 0.44 la ≈ 0.02 .

Comparativ cu degree și closeness, Katz nu oferă un avantaj major de predicție în aceste grafuri, indicând că structura locală și distanțele scurte sunt suficiente pentru a explica dinamica SIR.

6.4.2 Corelație cu `max_inf`

Același tipar ca celelalte: corelație mică pozitivă la p mic, negativă la $p = 0.10$ (≈ -0.16 Pearson). Katz nu poate prezice evenimentele extreme.

6.5 Fenomenul de Corelație Negativă la $p = 0.10$

Apariția corelației negative între centralități și `max_inf` la $p = 0.10$ este neintuitivă dar explicabilă. În acest regim epidemia a depășit pragul de percolatie: chiar și noduri periferice pot genera focare mari prin *efecte* stochastice. Nodurile cu centralitate mare infectează rapid vecinii direcți, consumând susceptibili locali și reducând potențialul de focar extrem. Evenimentele extreme sunt mai probabile din noduri cu conectivitate moderată, care accesează zone cu susceptibili neafecți.

6.6 Implicații Practice

Aplicații bazate pe rezultatele corelației:

1. Vaccinare / blocare informații (campanii preventive): Centralitatea clasică este utilă în regimul epidemic activ ($p \approx 0.04\text{--}0.10$). Se pot ținti nodurile cu degree, closeness sau Katz mare — calcul rapid, eficient.


2. Prevenirea celui mai rău scenariu (`max_inf`): Centralitatea clasică NU este suficientă. Sunt necesare simulări stochastice directe sau măsuri bazate pe influența empirică.

3. Eficiența computațională: Centralitățile clasice ($O(n^3)$ pentru Closeness, $O(n \cdot m)$ pentru Degree) sunt mult mai rapide de calculat decât simularea stochastică (300.000 rulari), dar cu putere predictivă limitată la scenariile extreme.

6.7 Concluzii Generale

Toate cele trei centralitati clasice (Degree, Closeness, Katz) sunt predictorii puternici pentru influenta medie (*mean_inf*) doar in regimul intermediar al probabilitatii p (≈ 0.04 – 0.10), unde procesul SIR este sensibil la structura rețelei.

In schimb, pentru influenta maxima (*max_inf*), niciuna nu ofera predictii consistente. Corelatiile sunt mici, instabile sau negative, aratand ca evenimentele extreme sunt dominate de dinamica stohastica si de conditiile initiale, nu de centralitate.



Aceasta concluzie confirma necesitatea abordarii stohastice din proiect: centralitatea clasica este o aproximare buna pentru comportamentul mediu al epidemiei, dar insuficienta pentru analiza de risc a scenariilor extreme. Cele doua abordari — clasica si stohastica — sunt **complementare**, nu concurente.


7 Rezultate

Acest capitol prezintă analiza datelor obținute în urma celor 300.000 de simulări SIR efectuate pe cele 6 rețele (3 reale și 3 generate). Rezultatele se concentrează pe corelația dintre centralitățile clasice și impactul stohastic al nodurilor, evaluat prin metricile *mean_inf* (media infectărilor) și *max_inf* (focarul maxim).


7.1 Analiza Corelațiilor în Funcție de Parametrul p

Evoluția corelațiilor variază critic în funcție de probabilitatea de infectare p , evidențiind trei regimuri distincte:

- **Regimul slab contagios** ($p = 0.01$): Corelațiile sunt moderate (Pearson ≈ 0.51 , Spearman ≈ 0.53), indicând faptul că, deși nodurile centrale tind să infecteze mai mulți vecini, structura locală și hazardul domină procesul.



- **Regimul epidemic activ** ($p = 0.04 - 0.10$): Aceasta este faza în care centralitățile devin predictorii excelenți. La $p = 0.1$, corelația Pearson pentru Degree și Closeness atinge valori de ≈ 0.82 [cite: 68, 78]. În acest interval, ranking-ul structural al nodurilor corespunde aproape direct cu impactul lor mediu în rețea.



- **Regimul saturat** ($p = 0.30 - 0.50$): Corelațiile scad spre 0. În acest stadiu, epidemia este atât de puternică încât infectează aproape întreaga rețea indiferent de sursa inițială, anulând importanța poziției structurale a nodului.



7.2 Predictibilitatea Evenimentelor Extreme (max_inf)

O observație majoră a rezultatelor este eșecul centralităților clasice de a prezice focarul maxim (max_inf). La $p = 0.1$, corelațiile devin chiar negative (≈ -0.15 pentru Pearson), ceea ce sugerează că nodurile cele mai conectate nu sunt neapărat cele care generează cele mai mari focare în scenariile cele mai defavorabile. Evenimentele extreme sunt dominate de variații stohastice și nu de topologia rețelei.

8 Concluzii

Studiul privind simularea SIR pe rețele complexe conduce la următoarele concluzii fundamentale:

- 1. Eficiența Centralităților Clasice:** Centralitățile de grad (Degree), proximitate (Closeness) și Katz sunt predictorii extrem de puternici pentru impactul mediu al unei epidemii, dar numai într-un regim specific de contagiozitate (p intermediar).
- 2. Limitările Structurale:** Nicio măsură de centralitate testată nu poate prezice cu acuratețe evenimentele de tip "cel mai rău scenariu" (max_inf), acestea fiind guvernate de dinamica stohastică a procesului de infectare.
- 3. Implicații Practice:**
 - Pentru campanii de prevenție generală (ex. vaccinare), utilizarea nodurilor cu centralitate mare este o strategie validă.
 - Pentru gestionarea riscurilor extreme, analiza structurală trebuie completată cu simulări stohastice directe, deoarece centralitatea singură poate induce în eroare.

4. **Rolul Densității:** Compararea între grafurile reale și cele generate a arătat că, deși densitatea facilitează propagarea, structura organică a rețelelor naturale creează tipare de dispersie diferite față de grafurile aleatorii.

În concluzie, centralitatea rămâne un instrument vital în epidemiologia computațională, însă aplicabilitatea ei depinde strict de parametrii dinamici ai agentului infectios.

Bibliografie

- [1] D. Kempe, J. Kleinberg si E. Tardos, “Maximizing the spread of influence through a social network,” in *Proc. 9th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2003, pp. 137–146.
- [2] M. Kitsak et al., “Identification of influential spreaders in complex networks,” *Nature Physics*, vol. 6, pp. 888–893, 2010.
- [3] C. Spearman, “The proof and measurement of association between two things,” *American Journal of Psychology*, vol. 15, pp. 72–101, 1904.
- [4] L. Katz, “A new status index derived from sociometric analysis,” *Psychometrika*, vol. 18, no. 1, pp. 39–43, 1953.
- [5] L. C. Freeman, “Centrality in social networks conceptual clarification,” *Social Networks*, vol. 1, no. 3, pp. 215–239, 1978.
- [6] NetworkX Developers, “Centrality — NetworkX documentation.” [Online]. Disponibil: <https://networkx.org/documentation/stable/reference/algorithms/centrality.html>. [Accesat: 2026].
- [7] SciPy Community, “scipy.stats — Statistical functions,” *SciPy Documentation*. [Online]. Disponibil: <https://docs.scipy.org/doc/scipy/reference/stats.html>. [Accesat: 2026].
- [8] M. Newman, *Networks: An Introduction*. Oxford University Press, 2010.